Ejercicio 07: Evaluación de impacto y auditoría de equidad

INF-8239 Ciencia de Datos II, Unidad 04 (U04.E07)

Estudiante	Jhonatan Cabral
Matrícula	BE2322
Repositorio	github.com/prodintdata/Ciencia-de-datos-II, Unidad IV/Ejercicio 07
Evidencia	U04_E07_Evidencias_Jhonatan Cabral.pdf (abrir en GitHub)
Base	LAB11 y LAB12, proyecto INF8239_U04_Gobernanza_DSS_Proyecto_Base_uv (uv, Python 3.12, fairlearn 0.12.0)
Decisión final	**Modificar y limitar** (sección 5)

Caso. El Territorial Review DSS ordena casos territoriales sintéticos para que un analista decida cuáles revisar primero. Hay 640 casos con zona, grupo protegido (G1, G2), tramo de edad, incidentes previos, infraestructura, exposición y una etiqueta binaria. Los datos no representan personas reales. Todas las cifras de este informe salen de archivos editables del repositorio (YAML, CSV y JSON), generados con semilla 42.

1. Finalidad, interesados y proporcionalidad

Finalidad	Priorizar casos territoriales sintéticos para revisión humana; solo recomienda un orden, no decide.
Decisión asistida	Orden en que el analista revisa la cola de casos; la decisión final siempre es humana.
Usuarios	Analistas territoriales capacitados y su supervisor.
Población afectada	Personas y hogares de las zonas cuyos casos entran en la cola, en especial grupos protegidos y personas de 60+.
Propietario	Dirección de Gestión de Riesgo Territorial.
Alternativa no predictiva	Revisión por orden de llegada (FIFO) con reglas simples y públicas, sin modelo.
Uso prohibido	Intervención automática, decidir elegibilidad, declarar emergencias o perfilar personas reales.
Condición de retiro	Suspender si el recall baja de 0.68, si la brecha entre grupos supera 0.16 o si se detecta un uso indebido o un daño.
Apelación	La persona afectada puede pedir revisión humana a un supervisor independiente, que responde en 10 días hábiles.

Actor	Beneficio	Daño posible	Poder	Participación
Persona afectada	Su caso se revisa más rápido si es urgente	Quedar mal priorizado o sufrir trato desigual por su grupo o edad	Bajo	Derecho a apelación y aviso de que se usa un sistema de apoyo
Operador (analista)	Organiza mejor su carga de trabajo	Confiar de más en el puntaje y perder criterio propio	Medio	Capacitación y reporte de errores o casos dudosos
Propietario institucional	Usa mejor los recursos de revisión	Responsabilidad legal y reputacional si el sistema causa daño	Alto	Aprueba el uso y decide continuar o retirar el sistema
Equipo de datos	Mejora el modelo con evidencia	Sesgos o errores técnicos no detectados	Medio	Auditorías periódicas y reporte de métricas al propietario

Proporcionalidad. El sistema solo ordena una cola: no decide elegibilidad ni intervenciones. No usa identificadores directos, y *protected_group* no entra al modelo base. Medí la alternativa no predictiva con reglas explícitas (incidentes ≥ 3 o infraestructura < 0.3): detecta más casos (recall 0.859), pero marca el 73 % de la cola, con una FPR de 0.559. El modelo solo se justifica si la capacidad de revisión es limitada.

2. Obligación legal, marco voluntario y recomendación ética

Tipo	Instrumento	Aplicación en este caso
Obligación legal	Ley 172-13 de Protección de Datos Personales y Constitución de la República Dominicana (igualdad e intimidad)	Con datos reales, protected_group y age_band serían datos personales: exigirían una base legal, minimización y derecho de acceso y rectificación. Una brecha sistemática contra un grupo exigiría corrección. Con datos sintéticos, la obligación no se activa
Marco voluntario	NIST AI RMF 1.0	Organiza el registro de riesgos y la evidencia en GOVERN, MAP, MEASURE y MANAGE (sección 3)
Recomendación ética	Criterio propio	Revisión humana de todos los casos, alternativa sin modelo como respaldo, soporte mínimo de 20 casos por clase en cada subgrupo (positivos para el recall, negativos para la FPR) y no usar el grupo al predecir. Ninguna norma lo exige; lo adopto porque el daño priorizado es no detectar un caso real

3. Registro de riesgos y NIST AI RMF

ID	Escenario	P × I	Control	Responsable	Evidencia	Residual
R02	El analista acepta el puntaje sin revisar el caso (sesgo de automatización)	3×3 = 9	Capacitación y revisión obligatoria del caso antes de cerrarlo	Supervisor de analistas	Registro de casos revisados y bitácora de capacitación	Medio
R01	El modelo prioriza peor a un grupo protegido o a personas de 60+ (sesgo por subgrupo)	2×4 = 8	Auditoría de recall y FPR por subgrupo con brecha máxima de 0.16	Equipo de datos	Reporte de equidad de LAB12	Alto
R07	El puntaje se usa para decidir elegibilidad o intervención automática (uso fuera de alcance)	2×4 = 8	Política de usos prohibidos y auditoría del uso real	Propietario institucional	Política firmada y registro de accesos	Alto
R03	Los datos cambian con el tiempo y el modelo pierde precisión (drift)	2×3 = 6	Validación temporal y monitoreo mensual del recall	Equipo de datos	Métricas de monitoreo por mes	Medio
R06	El operador no entiende por qué un caso tiene prioridad alta	3×2 = 6	Mostrar la explicación del puntaje en el tablero	Equipo de datos	Capturas del tablero y encuesta a operadores	Medio
R04	Reidentificación de personas o filtración de datos sensibles	1×4 = 4	Prohibir identificadores directos y restringir el acceso por rol	Equipo de datos	Validación de esquema y prueba test_privacy	Medio
R05	El sistema responde lento o se cae y retrasa la revisión	2×2 = 4	Latencia máxima de 500 ms y respaldo con orden FIFO	Equipo de datos	Prueba de latencia y runbook	Bajo
R08	La persona afectada no conoce o no usa la vía de apelación	1×3 = 3	Aviso claro y formulario de apelación accesible	Propietario institucional	Bitácora de apelaciones y tiempos de respuesta	Bajo

Prioritarios. R02, el sesgo de automatización, es el más probable y se controla con una revisión obligatoria registrada. R01, el sesgo por subgrupo, se midió en las secciones 4 y 5. R07, el uso fuera de alcance, depende de la política y no del modelo. R01 y R07 empatan en prioridad, pero considero más urgente R01 porque afecta a grupos protegidos.

Función	Evidencia	Lo que no demuestra
GOVERN	Propietario, usos prohibidos y RACI (lab11_impact.yml, governance.yml, raci.csv)	Que la política se cumpla
MAP	Finalidad, 4 interesados y 8 riesgos (reports/lab11/)	Riesgos no previstos

Función	Evidencia	Lo que no demuestra
MEASURE	Métricas por grupo e interseccionales con soporte por clase (reports/lab12/, reports/e07/) y validación temporal (reports/e07/)	Desempeño con datos reales
MANAGE	Retiro, apelación y decisión (DECISION_RECORD.md)	Que el retiro funcione en la práctica

4. Auditoría global, por grupo e interseccional

Prueba temporal de 160 casos (los posteriores al 2026-09-24). Métrica principal: brecha de recall, porque el daño priorizado es no detectar un caso real. Tolerancias: recall ≥ 0.68 y brechas ≤ 0.16. El soporte se juzga con el denominador de cada métrica: el recall con los positivos reales (n+) y la FPR con los negativos reales (n−). Una cifra se interpreta solo si su denominador tiene al menos 20 casos; si no, es exploratoria.

Modelo	Accuracy	Recall	FPR	Brecha recall	Brecha FPR	Tamaño	Entrenamiento
Baseline: todo positivo	0.575	1.000	1.000	0.000	0.000	–	–
Regresión logística	0.719	0.717	0.279	0.138	0.125	3.6 KB	1.32 s
Árbol (max_depth = 5)	0.706	0.717	0.309	0.181	0.168	7.9 KB	0.16 s

Modelo	Grupo	n	n+ / n−	Prevalencia	Recall	FPR	Tasa de selección
Logística	G1	101	49 / 52	0.49	0.653	0.250	0.446
Logística	G2	59	43 / 16	0.73	0.791	0.375*	0.678
Árbol	G1	101	49 / 52	0.49	0.633	0.269	0.446
Árbol	G2	59	43 / 16	0.73	0.814	0.438*	0.712

* La FPR de G2 se apoya en solo 16 negativos: es exploratoria.

Grupo	n	n+	n−	Recall log.	FPR log.	Recall árbol	FPR árbol	¿Se interpreta?
G1 · 18-29	18	4	14	0.750	0.143	0.750	0.214	No (n+ y n− < 20)
G1 · 30-44	24	16	8	**0.562**	0.125	0.625	0.375	No (n+ y n− < 20)
G1 · 45-59	35	17	18	0.588	0.389	0.647	0.278	No (n+ y n− < 20)
G1 · 60+	24	12	12	0.833	0.250	0.583	0.250	No (n+ y n− < 20)
G2 · 18-29	11	8	3	0.875	0.000	1.000	0.000	No (n+ y n− < 20)
G2 · 30-44	14	12	2	0.667	0.500	0.833	1.000	No (n+ y n− < 20)
G2 · 45-59	8	6	2	1.000	0.000	0.667	0.000	No (n+ y n− < 20)
G2 · 60+	26	17	9	0.765	**0.556**	0.765	0.556	No (n+ y n− < 20)

Lectura. El recall global de la logística (0.717) cumple, pero el de G1 (0.653) no: el promedio oculta una falla localizada. El árbol supera ambas brechas sin ganar utilidad y ocupa el doble, así que se descarta (Green AI). Con la logística, el subgrupo con menor recall es **G1 · 30-44 (0.562, 9 de 16 positivos)**, seguido de G1 · 45-59 (0.588, 10 de 17); G2 · 60+ tiene la FPR más alta (0.556, 5 de 9 negativos). Ningún subgrupo interseccional llega a 20 positivos ni a 20 negativos, así que estas cifras señalan dónde investigar, pero no permiten ordenar los subgrupos con seguridad: el intervalo de Wilson del 95 % del recall de G1 · 30-44 va de 0.332 a 0.769. Con un bootstrap de 1000 remuestreos, el intervalo del 95 % de la brecha de recall entre grupos va de 0.011 a 0.314: con 160 casos no se puede asegurar que esté por debajo de 0.16.

Una brecha no prueba discriminación causal. Las prevalencias difieren (0.49 frente a 0.73), las muestras son pequeñas y el modelo puede reproducir diferencias a través de variables proxy como la zona o la edad. La brecha obliga a investigar, pero no demuestra la causa.

5. Mitigación, trade-offs y decisión

Comparación exploratoria. Las variantes se compararon y se eligió una usando el mismo test de 160 casos, así que esta tabla es exploratoria: muestra qué alternativa validar, no prueba que mejore el sistema.

Variante	Accuracy	Recall	FPR	Brecha recall	Brecha FPR	Recall G1
Logística base	0.719	0.717	0.279	0.138	0.125	0.653
Logística, umbral 0.40	0.731	0.848	0.426	0.067	0.096	0.816
ExponentiatedGradient (paridad de recall)	0.744	0.728	0.235	0.030	0.101	0.714
Reglas sin modelo	0.681	0.859	0.559	0.084	0.087	0.898

Trade-offs. Bajar el umbral a 0.40 cierra la brecha (0.067), pero la FPR sube a 0.426: más alertas falsas y más carga de revisión, lo que agrava R02. ExponentiatedGradient (fairlearn) usa el grupo solo al entrenar: en este test reduce la brecha de recall de 0.138 a 0.030 y sube el recall de G1 a 0.714 sin perder accuracy. Tiene tres costos. (1) Con datos reales, usar el grupo al entrenar requeriría una base legal. (2) Sus predicciones son aleatorizadas, lo que dificulta explicarlas y apelarlas. (3) No corrige G1 · 45-59, que sigue en 0.588 (10 de 17 positivos).

5.1 Validación de la alternativa elegida

Para no juzgar la alternativa con los mismos datos con que se eligió, la validé con tres periodos temporales anteriores al test, que no intervinieron en la elección. En cada periodo, los modelos se entrenan con todo lo anterior y se evalúan con el bloque siguiente de 80 casos. Criterio fijado antes de ejecutar: la mejora se da por validada si el intervalo bootstrap pareado del 95 % de la reducción de la brecha de recall queda entero por debajo de 0, si la brecha baja en todos los periodos, si el recall agregado es ≥ 0.68 y si la FPR no sube más de 5 puntos.

Periodo de validación	Positivos G1 / G2	Brecha recall base	Brecha recall mitigado	Recall base	Recall mitigado
2026-05-13 a 2026-06-25	22 / 26	0.112	0.010	0.833	0.812
2026-06-26 a 2026-08-11	22 / 23	0.277	0.144	0.778	0.756
2026-08-12 a 2026-09-24	26 / 16	0.106	**0.168**	0.810	0.833
Agregado (240 casos)	70 / 65	0.164	0.089	0.807	0.800

Resultado: la mejora no queda validada. El modelo mitigado redujo la brecha en 2 de los 3 periodos, pero en el tercero la aumentó (0.168 frente a 0.106). En el agregado la bajó de 0.164 a 0.089, pero el intervalo pareado del 95 % de la diferencia va de −0.167 a +0.031 e incluye el 0. El recall (0.800) y la FPR (0.248 frente a 0.257) sí cumplen. Por eso no afirmo que sustituir el modelo base mejore el sistema fuera de esta muestra: la sustitución queda condicionada a validarla con datos nuevos (reports/e07/temporal_validation.csv y validation_summary.json). Los periodos también tienen poco soporte: en el tercero G2 tiene solo 16 positivos, por debajo del mínimo de 20, así que las brechas por periodo son exploratorias y el resultado se lee en el agregado.

Opción	Decisión	Razón
Desplegar	No	La brecha es incierta (intervalo hasta 0.314), el recall de G1 está bajo la tolerancia y los datos son sintéticos
Modificar	**Sí, condicionado**	La alternativa elegida es el modelo mitigado, pero su mejora no está validada fuera de esta muestra (5.1); solo sustituye al modelo base si se valida con datos nuevos
Limitar	**Sí**	Solo piloto, con revisión humana de todos los casos y las reglas sin modelo como respaldo; sin uso para elegibilidad ni intervención
No utilizar	No, por ahora	Se aplica si se cumple la condición de retiro o si el piloto no mejora a las reglas

Responsable y retiro. El propietario institucional decide el retiro, que se aplica si el recall baja de 0.68, si una brecha supera 0.16 o si se detecta un uso indebido o un daño. El sistema vuelve entonces a las reglas sin modelo. Cada mes se informa el recall de G1, el de G1 · 30-44 y G1 · 45-59, y la FPR de G2 · 60+, junto con sus positivos y negativos. El registro completo está en *reports/lab11/DECISION_RECORD.md*.

6. Artefactos y pruebas

Ruta	Contenido
student_inputs/	Ficha de impacto, interesados, registro de riesgos y decisión de LAB12
reports/lab11/, reports/lab12/	Riesgos priorizados, resumen NIST, registro de decisión, métricas e informe de auditoría
reports/e07/, scripts/e07_mitigation.py	Mitigación (comparación exploratoria), intervalos bootstrap y salida de consola (run_log.txt)
reports/e07/, scripts/e07_review.py	Soporte por clase con intervalos de Wilson (support_by_class.csv) y validación temporal (temporal_validation.csv, validation_summary.json)
tests/	14 pruebas, todas aprobadas: datos, privacidad, impacto, equidad, modelo, gobernanza, mitigación, soporte por clase y pliegues temporales

```
uv sync --frozen
uv run pytest -q
uv run python scripts/lab12_audit.py --model logistic
uv run python scripts/e07_mitigation.py
uv run python scripts/e07_review.py
```

7. Uso de inteligencia artificial

Herramienta	Claude Code (Claude Opus 5.5, de Anthropic) en Visual Studio Code, octubre y noviembre de 2026.
Mi trabajo	Instalé el entorno y ejecuté LAB11 en mi equipo (anexo, E1–E3), y después LAB12 con los comandos del README. Completé y ajusté la ficha de impacto, los interesados, el registro de riesgos y la decisión de LAB12. Ejecuté las pruebas y las validaciones, revisé las métricas por grupo y definí los criterios del análisis. Dirigí y supervisé el trabajo de la IA: le indiqué qué hacer en cada paso, revisé lo que proponía y decidí qué se aceptaba. En la revisión del trabajo decidí cómo incorporar las correcciones: mantener la alternativa elegida, presentar la comparación como exploratoria y no afirmar una mejora que la validación no confirma. Revisé el informe y el anexo corregidos, pedí verificaciones adicionales hasta que no quedaran errores y aprobé la versión final. Definí el repositorio de publicación, integré el proyecto en él e hice los commits y el push.
Prompts relevantes	Explicar qué pide cada campo de LAB11 y por qué. Revisar mis insumos y la redacción del registro de riesgos. Diagnosticar el error de lab11_impact.py y el fallo del push. Proponer un análisis de mitigación con Fairlearn y sus pruebas. Revisar el informe contra el mandato y la rúbrica. Incorporar correcciones.
Apoyo recibido	Explicaciones, propuestas de redacción que revisé y ajusté, diagnóstico de errores, el código del módulo de mitigación, de la tabla de soporte por clase y de la validación temporal, y el formato de este PDF.
Verificaciones	Comparé las cifras del informe con los CSV y JSON generados y con la salida de consola. Repetí el análisis y obtuve resultados idénticos. Confirmé que las 14 pruebas pasan.
Correcciones	(1) El script base lab11_impact.py tenía un error de sintaxis. (2) Matizamos la lectura «la logística cumple las brechas» con intervalos de confianza. (3) Medimos la alternativa sin modelo en lugar de solo enunciarla. (4) En una revisión posterior, con apoyo de la IA, se corrigió el subgrupo con menor recall (G1 · 30-44), el soporte se juzgó por clase y la alternativa elegida se validó con periodos anteriores al test. Yo decidí que, como la validación no confirma la mejora, el informe no debía afirmarla.
Responsabilidad	Los valores del análisis (daño priorizado, tolerancias, soporte mínimo por clase y decisión final) son míos. Puedo explicar cada parte y asumo la responsabilidad de lo entregado.

8. Referencias

Agarwal, A., Beygelzimer, A., Dudík, M., Langford, J., & Wallach, H. (2018). *A reductions approach to fair classification* (arXiv:1803.02453). arXiv. https://doi.org/10.48550/arXiv.1803.02453

National Institute of Standards and Technology. (2023). *Artificial Intelligence Risk Management Framework (AI RMF 1.0)* (NIST AI 100-1). https://doi.org/10.6028/NIST.AI.100-1

Weerts, H., Dudík, M., Edgar, R., Jalali, A., Lutz, R., & Madaio, M. (2023). *Fairlearn: Assessing and improving fairness of AI systems* (arXiv:2303.16626). arXiv. https://doi.org/10.48550/arXiv.2303.16626